Data Mining Project

จัดกลุ่มและแนะนำเพลงจาก Top Spotify Songs 2023

ผู้จัดทำ
016940664002-2 นาย รณฤทธิ์ รับรอง | เขียน code
016940664056-8 นาย นันทวุฒิ แก้วแดง | หา data-set
016940664012-1 นาย กนธี สิงโห | ออกแบบระบบ

ชุดข้อมูล: Top Spotify Songs 2023 (Kaggle)

ที่มาและความน่าสนใจของชุดข้อมูล

953

เพลงในชุดข้อมูล

24

คอลัมน์ (เสียง ความนิยม วันที่ปล่อย)

4

แพลตฟอร์ม: Spotify, Apple, Deezer, Shazam

- Top Spotify Songs 2023 จาก Kaggle เผยแพร่โดย Nidula Elgiriyewithana
- รายการเพลงที่โด่งดังที่สุดปี 2023 บน Spotify
- มีทั้งค่าเสียง (bpm, danceability, valence ฯลฯ) และความนิยมข้ามแพลตฟอร์ม
- น่าสนใจ: ตอบได้ว่าเพลงฮิตมีลักษณะอย่างไร และต่อยอดเป็นระบบแนะนำเพลงได้

แหล่งข้อมูล: kaggle.com/datasets/nelgiriyewithana/top-spotify-songs-2023

ปัญหาที่พบ

ด้านข้อมูล

- streams เสียหาย 1 แถว
- ตัวเลขเป็นข้อความมีคอมมา เช่น "1,234"
- ค่าว่าง: Shazam 50 แถว, key 95 แถว
- เพลงซ้ำ 1 แถว
- ชื่อเพลง/ศิลปินเพี้ยน 91 แถว (กู้คืนไม่ได้)

ด้านการวิเคราะห์

- ข้อมูลความนิยมเบ้มาก (skew 2.0–2.9)
- สเกลต่างกัน: bpm ราว 60–200 เทียบกับ 0–100%
- ไม่มี genre และไม่มี label
- ไม่มีข้อมูลพฤติกรรมผู้ใช้ จึงทำ supervised ไม่ได้

โจทย์: จัดกลุ่มเพลงให้ตีความได้ แล้วนำกลุ่มไปแนะนำเพลง โดยไม่มี label และไม่มี genre

วิธีการแก้ปัญหาด้วย Data Mining

1

Data Cleaning

แปลงตัวเลข ตัดแถวเสียหาย จัดการค่าว่าง

2

Feature Engineering

log1p, Standardize, เลือกฟีเจอร์

3

K-means ×2

Audio และ Popularity (k=3)

4

Evaluation

Elbow, Silhouette, ดูโปรไฟล์กลุ่ม

5

Recommend

recommend(song, model, count)

ทำไมใช้ K-means (Unsupervised Learning)

- ไม่มี label/genre จึงจัดกลุ่มจากความคล้ายของข้อมูลตัวเลข
- ตีความผลได้จากค่ากลางของแต่ละกลุ่ม
- ทำ 2 มุมมอง: Audio (ฟังคล้ายกัน) และ Popularity (ดังระดับเดียวกัน)

Feature Engineering

ขั้นตอน

- แปลงชนิดข้อมูล: ลบคอมมา แล้วเป็นตัวเลข
- ค่าว่าง: Shazam เติม 0 (ไม่เคยติดชาร์ต)
- log1p กับข้อมูลความนิยม เพื่อลดความเบ้
- StandardScaler: ค่าเฉลี่ย 0, ส่วนเบี่ยงเบน 1

ฟีเจอร์	skew ก่อน	หลัง log1p
streams	2.0	-1.2
in_spotify_playlists	2.9	0.0
in_spotify_charts	2.6	0.4

ความเบ้ใกล้ 0 = ข้อมูลสมมาตร

Audio (8 ฟีเจอร์)

- bpm, danceability, valence, energy, acousticness, instrumentalness, liveness, speechiness

Popularity (3 ฟีเจอร์)

- streams, in_spotify_playlists, in_spotify_charts
- ไม่ใช้ playlist ของ Apple/Deezer เพราะสัมพันธ์กับ Spotify 0.73–0.85 (นับซ้ำ)

Model: K-means Clustering และระบบแนะนำเพลง

Model 1: Audio K-means (k=3)

ฟีเจอร์เสียง 8 ตัว (Standardize)

- Upbeat Dance Party: 556 เพลง
- Acoustic Chill Melancholic: 249 เพลง
- Rap Hip-Hop Talk-Heavy: 147 เพลง

Model 2: Popularity K-means (k=3)

streams, playlist, ชาร์ต (log1p + Standardize)

- All-Time Megahits: 329 เพลง (streams มัธยฐาน 921 ล้าน)
- Moderate Hits: 382 เพลง (190 ล้าน)
- Top Charting Hits: 241 เพลง (161 ล้าน, ปี 2023)

recommend(song, model, count): หา cluster ของเพลงเริ่มต้น → ดึงเพลงอื่นใน cluster เดียวกัน → เรียงตามระยะห่าง Euclidean → คืน count เพลงที่ใกล้ที่สุด

การตั้งชื่อกลุ่ม: วิเคราะห์จากฟีเจอร์ใด

Popularity Model: ดูค่ามัธยฐานของแต่ละกลุ่ม

ชื่อกลุ่ม	ฟีเจอร์ที่ใช้ตัดสิน	ค่าของกลุ่ม
All-Time Megahits	streams สูงสุดในทุกกลุ่ม	streams 921 ล้าน, playlist 7,963, ปีมัธยฐาน 2020
Top Charting Hits	ใน 2 กลุ่มที่เหลือ in_spotify_charts สูงกว่า	ติดชาร์ต 13 ครั้ง (อีกกลุ่ม 0), ปีมัธยฐาน 2023
Moderate Hits	กลุ่มที่เหลือ	ติดชาร์ต 0 ครั้ง, streams 190 ล้าน, playlist ราว 1,590

Audio Model: ดูค่าเฉลี่ยของแต่ละกลุ่ม

ชื่อกลุ่ม	ฟีเจอร์ที่ใช้ตัดสิน	ค่าของกลุ่ม
Rap Hip-Hop Talk-Heavy	speechiness_% สูงสุดในทุกกลุ่ม	speechiness 30.3 (กลุ่มอื่น 5.6 และ 6.8)
Acoustic Chill Melancholic	ใน 2 กลุ่มที่เหลือ acousticness_% สูงกว่า	acousticness 52.4 (อีกกลุ่ม 15.9), energy 47.1 และ valence 33.7 ต่ำสุด
Upbeat Dance Party	กลุ่มที่เหลือ	valence 59.6 และ energy 72.3 สูงสุด, danceability 70.9

ชื่อกลุ่มเป็นการตีความของผู้วิเคราะห์ ตั้งอัตโนมัติด้วยกติกาข้างต้น (class AutoLabel) ไม่ใช่ผลที่โมเดลให้โดยตรง

ผลการแนะนำเพลง

เพลงเริ่มต้น: Perfect - Ed Sheeran | กลุ่มเสียง: Acoustic Chill Melancholic | กลุ่มความนิยม: All-Time Megahits

model = audio: เพลงที่เสียงคล้ายกัน

#	เพลง	ศิลปิน
1	All Too Well (10 Minute Version)…	Taylor Swift
2	Maroon	Taylor Swift
3	After Hours	The Weeknd
4	Am I Dreaming (Metro Boomin…)	A$AP Rocky, Metro Boomin, Roisee
5	Creep	Radiohead

model = pop: เพลงที่ดังระดับเดียวกัน

#	เพลง	ศิลปิน
1	Say You Won't Let Go	James Arthur
2	Shallow	Lady Gaga, Bradley Cooper
3	Circles	Post Malone
4	Believer	Imagine Dragons
5	Something Just Like This	The Chainsmokers, Coldplay

เรียงจากใกล้ไปไกล (Euclidean distance) ภายในกลุ่มเดียวกัน | audio ฟังคล้ายกัน แต่ pop ได้เพลงที่ดังระดับเดียวกัน ไม่จำเป็นต้องฟังคล้ายกัน

Evaluation

Model	k	Silhouette	ความหมาย
Audio	3	0.206	ขอบเขตกลุ่มซ้อนกัน (k=2: 0.228, k=4: 0.216)
Popularity	3	0.367	แยกชัดกว่า (k=2: 0.376, k=4: 0.363)

วิธีประเมิน

- Elbow และ Silhouette ที่ k=2–8
- เลือก k=3 เพราะตีความได้ (k=2 ได้แค่ 2 กลุ่ม)
- ตรวจโปรไฟล์กลุ่มและตัวอย่างเพลง
- ไขว้ผลของ 2 โมเดล

ข้อจำกัด

- Audio ~0.2: เพลงใกล้เส้นแบ่งอาจอยู่คนละกลุ่ม
- ไม่มี ground truth จึงวัดความแม่นยำของการแนะนำไม่ได้
- ชื่อกลุ่มตั้งจากโปรไฟล์โดยผู้วิเคราะห์

สรุปผล

ผลการจัดกลุ่ม

- Audio: เต้นรำร่าเริง / อะคูสติกเศร้า / แร็พ
- Popularity: เมกะฮิต / ปานกลาง / ติดชาร์ตมาแรง
- Popularity แยกชัดกว่า (0.367 เทียบ 0.206)

ข้อค้นพบ

- เพลงอะคูสติกเศร้าอยู่กลุ่มเมกะฮิต 40% (แร็พ 23%)
- เพลงปี 2023 กระจุกในกลุ่ม Top Charting
- เป็นแนวโน้ม ไม่ได้ทดสอบทางสถิติ

การแนะนำเพลง

- Perfect + audio: All Too Well, Maroon, After Hours
- Perfect + pop: Say You Won't Let Go, Shallow
- audio = เสียงคล้ายกัน, pop = ดังระดับเดียวกัน

ข้อจำกัด: ไม่มี genre และพฤติกรรมผู้ใช้, ข้อมูลมี 952 เพลงที่ฮิตอยู่แล้ว | ต่อยอด: เพิ่ม genre จาก Spotify API และรวมผล 2 โมเดล